UNIVERSIDADE FEDERAL DE UBERLÂNDIA

Pedro de Araujo Ribeiro

Quantificando Fernando Pessoa: Análise E Classificação De Textos

Uberlândia, Brasil

2026

UNIVERSIDADE FEDERAL DE UBERLÂNDIA

Pedro de Araujo Ribeiro

Quantificando Fernando Pessoa: Análise E Classificação De Textos

Trabalho de conclusão de curso apresentado à Faculdade de Computação da Universidade Federal de Uberlândia, como parte dos requisitos exigidos para a obtenção título de Bacharel em Ciência da Computação.

Orientador: Dr. Pedro Franklin Cardoso Silva

Universidade Federal de Uberlândia – UFU

Faculdade de Computação

Bacharelado em Ciência da Computação

Uberlândia, Brasil

2026

Pedro de Araujo Ribeiro

Quantificando Fernando Pessoa: Análise E Classificação De Textos

Trabalho de conclusão de curso apresentado à Faculdade de Computação da Universidade Federal de Uberlândia, como parte dos requisitos exigidos para a obtenção título de Bacharel em Ciência da Computação.

Trabalho aprovado. Uberlândia, Brasil, 20 de março de 2026:

Dr. Pedro Franklin Cardoso Silva
Orientador

Dra. Patricia Viana da Silva
Convidada

Dr. Rodrigo Sanches Miani
Convidado

Uberlândia, Brasil
2026

Resumo

Este trabalho consiste da análise quantitativa do corpo de produções de Fernando Pessoa e seus heterônimos com a intenção de diferenciá-los uns dos outros através de técnicas de visualização estatísticas e análise de dados. A metodologia consistiu, em ordem, de: extração dos poemas de um arquivo na internet, visualização do conjunto de dados obtidos, seleção de observações relevantes, criação de variáveis para quantificação dos textos a partir da linguagem natural, análise destas variáveis, aplicação de modelos de classificação em relação aos heterônimos, e por fim análise destes resultados.

Por meio destes foi possível observar o formato dos textos em relação as métricas criadas, quais delas eram mais relevantes para discernir a qual autor pertencia cada poema, quais modelos dentre os estudados eram mais eficientes, e como a acurácia pode ser melhorada via métodos estatísticos.

Palavras-chave: Visualização, Fernando Pessoa, Estilometria, Atribuição, Poemas.

Lista de ilustrações

Figura 1 – Distribuição dos tipos de obra por autor 15
Figura 2 – Distribuição separada de obras por autor 15
Figura 3 – Distribuição separada de obras por autor, >= 90 obras 16
Figura 4 – Quantidade de estrofes e de palavras 18
Figura 5 – Composição geral dos textos 19
Figura 6 – Riqueza vocabular 20
Figura 7 – Entropia antes e depois da normalização 21
Figura 8 – Primeira árvore de decisão gerada 24
Figura 9 – Primeira árvore de decisão após poda 25
Figura 10 – Importância de variáveis 27

Lista de tabelas

Tabela 1 – Quantidade de obras por autor 14
Tabela 2 – Distribuição por heterônimo 16
Tabela 3 – Variáveis notáveis 17
Tabela 4 – Matriz de confusão: Primeira árvore 24
Tabela 5 – Matriz de confusão: Primeira árvore após poda 25
Tabela 6 – Matriz de confusão: Primeira floresta aleatória 26
Tabela 7 – Matriz de confusão: Segunda floresta aleatória, sem ponto e vírgula . . 26
Tabela 8 – Matriz de confusão: SVM 26
Tabela 9 – Matriz de confusão: Regressão logística multinomial 28
Tabela 10 – Diferentes acurácias por partição 28
Tabela 11 – Acurácias via *K-Fold CV* 28
Tabela 12 – Distribuição por heterônimo pós balanceamento 29
Tabela 13 – Acurácias do conjunto balanceado via *K-Fold CV* 29
Tabela 14 – Matriz de confusão: Floresta aleatória em conjunto balanceado 29

Lista de abreviaturas e siglas

SVMs	Support Vector Machines
PLN	Processamento de Linguagem Natural
SMOTE	Synthetic minority oversampling technique

Sumário

1 INTRODUÇÃO . . . 8

2 REVISÃO BIBLIOGRÁFICA E FUNDAMENTAÇÃO . . . 10
2.1 Revisão Bibliográfica . . . 10
2.2 Fundamentação Teórica . . . 11
2.2.1 Algoritmos de classificação . . . 11
2.2.2 Processamento de Linguagem Natural . . . 12

3 METODOLOGIA . . . 13
3.1 Extração dos poemas . . . 13
3.2 Visualização dos dados . . . 15
3.2.1 Distribuição de obras . . . 15
3.2.2 Limpeza do corpus . . . 16
3.2.3 Formato e composição dos textos . . . 16
3.3 Métodos de classificação . . . 19
3.3.1 Árvore de decisão . . . 20
3.3.2 Floresta aleatória . . . 21
3.3.3 Support Vector Machine . . . 21
3.3.4 Regressão logística . . . 22
3.3.5 Regressão logística multinomial . . . 22

4 RESULTADOS . . . 23
4.1 Testes individuais . . . 23
4.1.1 Árvore de decisão . . . 23
4.1.2 Floresta aleatória . . . 25
4.1.3 SVMs . . . 26
4.1.4 Regressão logística multinomial . . . 26
4.1.5 Impacto da partição aleatória . . . 27
4.2 Testes em escala . . . 28
4.2.1 K-Fold Cross Validation . . . 28
4.3 Observações sintéticas . . . 28

5 CONCLUSÃO . . . 30

REFERÊNCIAS . . . 31

1 Introdução

Fernando Pessoa, renomado autor, produziu poemas sob diversos heterônimos, cada um com estilos e técnicas de escrita distintos. Alberto Caeiro, por exemplo, demonstra foco e apreço pela natureza e pela sensitividade humana, enquanto Álvaro de Campos valoriza a modernidade, apresentando, junto a esse sentimento, uma angústia pessoal (SOUZA, 2026). Nesse contexto, surge a oportunidade de aplicar técnicas de aprendizado de máquina e visualização de dados para analisar tais textos e buscar atribuí-los a um heterônimo específico.

Tais técnicas, aplicadas ao processamento e à classificação de textos, são de extrema relevância para conceitos avançados como mineração de dados, análise de sentimentos e modelos de linguagem de larga escala (Large Language Models), entre outros (TAHA et al., 2024). Dessa forma, é pertinente explorar metodologias que possam aumentar a eficiência do processo de classificação e, a longo prazo, elevar o desempenho dessas aplicações. Além disso, a natureza lírica e subjetiva de textos artísticos oferece um desafio particular para algoritmos computacionais, que podem encontrar dificuldades ao buscar padrões em obras de tamanha abstração.

Historicamente, diversos estudiosos da literatura analisaram as particularidades dos heterônimos de Pessoa. No entanto, na área da ciência de dados, há poucos estudos relacionados a este tema. O primeiro (TEIXEIRA; COUTO, 2015) contempla poemas atribuídos a Ricardo Reis e Álvaro de Campos e utiliza SVMs para realizar a classificação, com foco nas etapas de pré-processamento. O estudo considera métricas como extensão dos poemas, comprimento das palavras e frequência relativa de termos. Já o segundo (MATSUMOTO et al., 2020) é mais abrangente, incluindo a extração de poemas via web scraping e uma etapa de processamento de texto mais direta. Este último estudo faz uso de obras de Ricardo Reis, Álvaro de Campos, Alberto Caeiro e Bernardo Soares.

Diante das pesquisas já realizadas, o objetivo primário deste trabalho é produzir e apresentar um entendimento mais abrangente dos componentes quantitativos de produções textuais — como densidade de pontuação e tamanho médio de versos — no contexto da obra de Fernando Pessoa. Sendo assim, a metodologia consiste em três etapas distintas: extração de informações utilizando web scraping; visualização de tendências e padrões nos textos; e classificação dos poemas em relação aos seus autores.

Além disso, o objetivo secundário é testar e comparar diversos algoritmos visando obter o melhor desempenho possível nas classificações. É importante reconhecer as limitações de uma base de dados como esta, na qual certos autores não possuem volume de obra suficiente para o treinamento de modelos, somado ao fato de que dificilmente

surgirão novas observações para validação externa. Portanto, técnicas de validação cruzada (Cross-Validation) e reamostragem (Resampling) foram empregadas, juntamente com uma restrição estratégica a obras poéticas, desconsiderando a prosa por razões de complexidade do problema.

Para alcançar estes objetivos, utilizou-se a linguagem de programação R e a IDE RStudio, e um repositório com todos os códigos está disponível no *Github*(RIBEIRO, 2026b). Cada etapa envolveu diferentes áreas da ciência de dados, a saber:

1. *Web scraping*, realizado no site Arquivo Pessoa (AREAL; ESTEVES; NEVES, 2009).
2. Extração de atributos textuais, utilizando Expressões Regulares (Regex).
3. Classificação, utilizando Árvore de Decisão, Floresta Aleatória, SVMs e Regressão Logística Multinomial.
4. Validação, utilizando *K-fold Cross-Validation*.
5. Geração de dados sintéticos, utilizando SMOTE.

2 Revisão Bibliográfica e Fundamentação

2.1 Revisão Bibliográfica

A área de *Machine Learning* e os algoritmos de classificação podem ser aplicados na identificação de textos e, como elencado por Nirkhi e Dharwal (NIRKHI; DHARASKAR, 2013), na atribuição de autoria. O referido artigo não realiza um estudo experimental próprio a partir de um conjunto de dados específico, optando por comparar o uso desses conhecimentos em diversos outros estudos e o arcabouço teórico por trás deles. A teoria é dividida em dois campos: *Machine Learning* e *Statistical Univariate*, cada um englobando metodologias comumente usadas na área. Ao final, não é apresentada uma conclusão definitiva sobre qual método é mais eficiente, porém nota-se a alta frequência com que SVMs são utilizadas nessas aplicações — uma tendência que se mantém em trabalhos subsequentes.

Sabendo da capacidade dos modelos estatísticos e de *Machine Learning* para problemas de atribuição autoral, foi realizado um estudo (TEIXEIRA; COUTO, 2015) que visava testar a eficiência de diferentes técnicas e métricas de classificação de texto para diferenciar poemas escritos por Fernando Pessoa e atribuídos a diferentes heterônimos. Para tal, foram utilizadas as identidades de Álvaro de Campos e Ricardo Reis. Todos os poemas atribuídos a eles foram computados e submetidos à seguinte metodologia: a eficiência de cinco etapas de processamento de texto foi testada de forma iterativa (ou seja, a etapa 1 seguida das etapas 1 e 2, e assim por diante). Em seguida, foram testadas quatro métricas de avaliação de frequência de termos. Por fim, realizou-se uma análise do impacto de poemas longos na acurácia do modelo. Concluiu-se que os métodos empregados foram suficientes para diferenciar os heterônimos, que o impacto do tamanho dos poemas nos resultados foi inconclusivo e que, futuramente, o uso de métricas de relevância em vez de frequência poderia promover melhores resultados.

Nesse contexto, um grupo diferente de autores (MATSUMOTO et al., 2020) buscou realizar um estudo semelhante, utilizando poemas de Álvaro de Campos, Alberto Caeiro, Bernardo Soares e Ricardo Reis, com o objetivo de testar a aplicação de classificadores de texto. A metodologia consistiu em uma etapa de extração de todas as obras de Fernando Pessoa, seguida da remoção de textos em inglês ou de heterônimos com poucas produções. O passo de pré-processamento do texto foi simplificado e não testou metodologias variadas, aplicando as cinco etapas mencionadas no artigo anterior. A métrica de avaliação de relevância também foi mais direcionada, optando-se diretamente pelo *Term Frequency-Inverse Document Frequency* (TF-IDF). Foram realizados testes com SVMs e *Naive Bayes*, concluindo-se que as SVMs produziram resultados superiores.

Embora estas sejam as únicas produções encontradas que utilizam classificação, há um artigo em espanhol (SKORINKIN; OREKHOV, 2023) com uma abordagem distinta. Nele, o autor faz uso do "Método Delta", que quantifica a semelhança entre textos, e compara a "distância"entre obras dos diferentes heterônimos de Pessoa com a distância entre obras de autores distintos. O estudo concluiu que a diferença estilística entre os heterônimos é tão significativa que se assemelha à diferença encontrada entre autores inteiramente diversos.

Fora do escopo da obra de Fernando Pessoa, existem estudos sobre atribuição de autoria em outros contextos. Um deles (JUSTINO, 2010) visa, em suas próprias palavras, "avaliar estatisticamente a importância da utilização de características da língua portuguesa para a identificação de autoria em documentos questionados", com foco no âmbito jurídico e legal. Nesse trabalho, o autor utilizou métricas e modelos semelhantes aos deste TCC, porém com um detalhamento e foco nos componentes gramaticais e linguísticos consideravelmente maior.

2.2 Fundamentação Teórica

2.2.1 Algoritmos de classificação

Um modelo de classificação é um algoritmo treinado a partir de um conjunto de dados, no qual cada unidade individual é uma "observação"composta por uma ou mais "características"(*features*) e uma "variável resposta", com o intuito de classificar novos conjuntos de dados similares. Esta modalidade de *Machine Learning* é denominada "aprendizado supervisionado"(JAMES et al., 2013).

No processo de avaliação da performance do modelo, é usualmente empregada uma "matriz de confusão"para evidenciar a relação entre falsos positivos, falsos negativos, verdadeiros positivos e verdadeiros negativos (ZUMEL; MOUNT, 2014). Diferentes problemas exigem prioridades distintas para essas métricas: um modelo para diagnóstico de doenças deve priorizar a minimização de falsos negativos, enquanto um sistema para condenação criminal deve buscar a minimização de falsos positivos. Embora mais aplicada em classificações binárias, a matriz de confusão também pode ser utilizada para variáveis resposta com três ou mais categorias.

Além disso, são necessários métodos de reamostragem (*resampling*) para particionar o conjunto de dados em "treino"e "teste"(JAMES et al., 2013), visto que a eficácia do modelo depende de uma partição adequada do *dataset* original. Uma escolha inadequada seria, por exemplo, em um conjunto onde apenas 5% das observações são de uma classe específica concentrada ao final do arquivo; se o modelo for treinado apenas nos primeiros 80% dos dados, ele será incapaz de detectar tal classe.

Uma aplicação clássica destes modelos é na detecção de fraudes em cartões de crédito (SHEN; TONG; DENG, 2007), onde o histórico de comportamento de clientes é utilizado para identificar padrões indicativos de atividades suspeitas. Atualmente, o estado da arte da classificação contempla algoritmos baseados em redes neurais (AHMED et al., 2023), embora modelos como *Naive Bayes* e SVMs ainda se destaquem pela relativa simplicidade e eficiência.

2.2.2 Processamento de Linguagem Natural

O Processamento de Linguagem Natural (PLN) consiste em quantificar e codificar palavras e sentenças em componentes que possam ser interpretados por algoritmos. De forma inversa, o processo também pode ser utilizado para transformar dados gerados por computadores em texto legível para seres humanos.

Nesse contexto, utiliza-se o conceito de "tokenização"(BIRD; KLEIN; LOPER, 2009), em que palavras são representadas por *tokens*. A utilidade dessa representação reside na possibilidade de mapear diferentes variações de uma palavra para um mesmo *token*. Por exemplo, a lista de termos "compra", "comprar", "compras" pode ser reduzida à raiz comum "compr-". Para tal, empregam-se expressões regulares (*regex*) (BIRD; KLEIN; LOPER, 2009) na identificação de padrões textuais.

Outro conceito fundamental para este trabalho é a estilometria. Definida por Justino (JUSTINO, 2010) como uma área da estilística que trabalha com a análise quantitativa do estilo de escrita, seu principal objetivo é encontrar informações sobre a autoria por meio de características mensuráveis do texto.

Aplicações de extrema relevância do PLN incluem os mecanismos de busca (*search engines*) (YUE et al., 2012), onde pesquisas curtas são associadas a grandes bases de dados, e a classificação de textos para detecção de *emails spam* (SEL; HANBAY, 2019), notícias falsas (*fake news*) ou discurso de ódio. Atualmente, o estado da arte do PLN encontra-se nos modelos de linguagem de larga escala (*Large Language Models*) (YAN; XIAO; JIN, 2024), cujo funcionamento envolve arquiteturas complexas como redes neurais e mecanismos de atenção, tecnologias que seriam impossíveis sem as bases do PLN.

3 Metodologia

3.1 Extração dos poemas

Os poemas estudados foram adquiridos a partir do site Arquivo Pessoa(AREAL; ESTEVES; NEVES, 2009), cada poema se encontra em uma página cuja URL segue o formato a seguir:

```
http://arquivopessoa.net/textos/[numero]
```

O código HTML das páginas é uniforme e contém os seguintes campos relevantes:

```
<div class="autor">[autor]</div>
<h1 class="titulo-texto">[titulo]</h1>
<div class="texto-poesia">[corpo do texto]<\div>
<div class="texto-prosa">[corpo do texto]<\div>
<div class="data">[data de publicacao]</div>
<div class="biblio">[bibliografia]</div>
```

A partir dessas informações, foram feitas as seguintes considerações:

- Uma dada obra pode ser classificada exclusivamente como *poesia* ou *prosa*, estando presente apenas um dos campos de texto mencionados.
- O número identificador na URL varia no intervalo de 0 a 5000, conforme delimitado em estudos prévios sobre a plataforma.

Sendo assim, foi decidido que uma observação do conjunto de dados conterá as seguintes variáveis:

1. ID, referente ao número usado na URL
2. Autor
3. Titulo
4. Tipo, referente a prosa ou poesia
5. Corpo
6. Data
7. Biblio

Para realizar a extração das obras e construção do conjunto de dados foi usado um código em R(RIBEIRO, 2026c) que segue o algoritmo abaixo:

```
i <- 0
dataset <- vazio

enquanto i <= 5000:
    html <- acessar(http://arquivopessoa.net/textos/i)
    se(html valido):
        obs.ID <- i
        obs.autor <- html.buscar("autor")
        obs.titulo <- html.buscar("titulo-texto")
        se(html.buscar("texto-prosa") = vazio):
            obs.tipo <- poesia
            obs.corpo <- html.buscar("texto-poesia")
        caso contrario:
            obs.tipo <- prosa
            obs.corpo <- html.buscar("texto-prosa")
        obs.data <- html.buscar(data)
        obs.biblio <- html.buscar(biblio)
        dataset.inserir(obs)
        i <- i + 1
```

Ao executar o código, foram obtidas 4530 observações pertencentes a 40 heterônimos. A distribuição inicial das obras é apresentada na Tabela 1.

Autor	Nº poemas
Fernando Pessoa	2814
Bernardo Soares	504
Álvaro de Campos	397
Ricardo Reis	307
Alexander Search	139
Alberto Caeiro	127
António Mora	95
Demais 33 autores	147

Tabela 1 – Quantidade de obras por autor

A categoria "Demais 33 autores"engloba nomes com menos de 90 obras (média de 4,45 e mediana de 2), sendo desconsiderada das análises subsequentes. Além disso, as obras atribuídas ao ortônimo[1] Fernando Pessoa foram descartadas devido ao volume excessivamente superior aos demais, o que causaria um desbalanceamento crítico nos modelos.

[1] Nome civil completo e correto ou o ordinariamente declarado pelo próprio denominado.

3.2 Visualização dos dados

3.2.1 Distribuição de obras

Conforme discutido na seção anterior, as obras classificam-se em poesia ou prosa. A distribuição dessas categorias na base de dados é apresentada na Figura1:

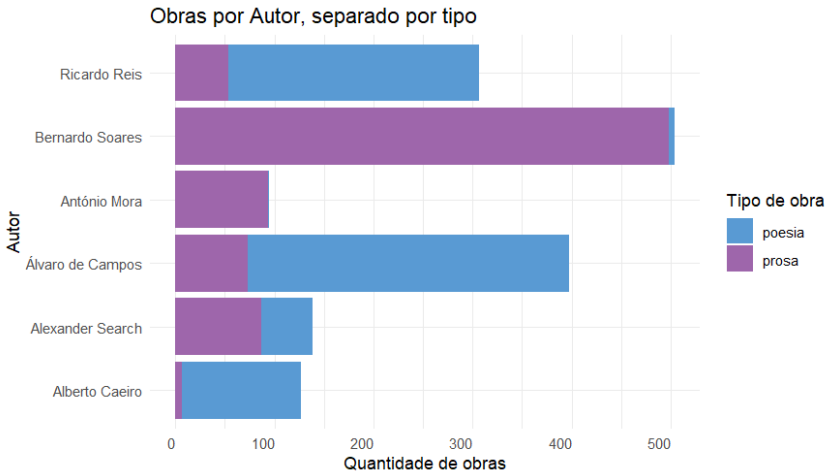

Figura 1 – Distribuição dos tipos de obra por autor

Fonte: Autor

Devido à diferença notável em estrutura e formato entre poesias e prosas, e à maneira desproporcional com que aparecem em certos autores, optou-se por não mantê-las em um mesmo conjunto de dados para análise e processamento. Sendo assim, realizou-se a separação em dois subconjuntos distintos.

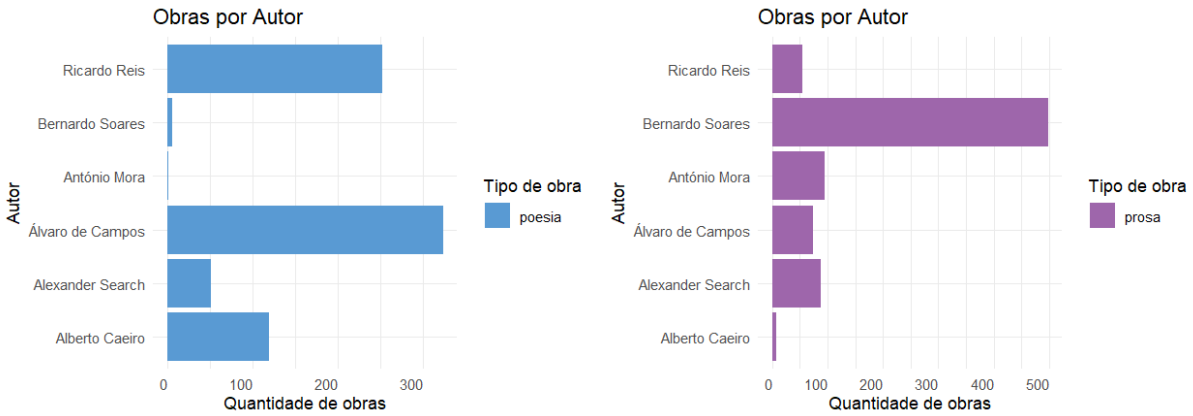

Figura 2 – Distribuição separada de obras por autor

Fonte: Autor

A Figura 2 demonstra claramente que, para certos tipos de obra, alguns autores apresentam uma produção muito reduzida, reforçando a necessidade de remover classes com dados insuficientes para o treinamento dos modelos.

3.2.2 Limpeza do corpus

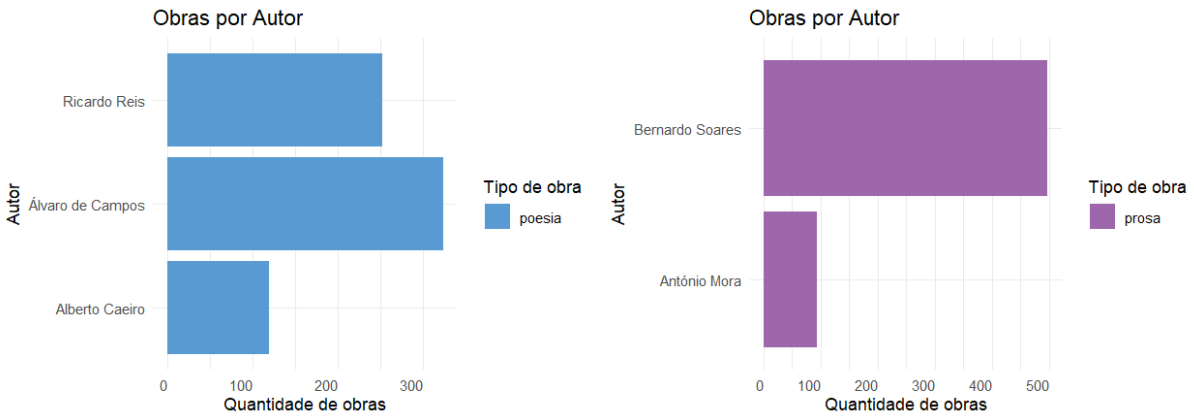

Figura 3 – Distribuição separada de obras por autor, >= 90 obras

Fonte: Autor

Tendo em vista a existência de apenas dois autores de prosa com mais de 90 obras e a disparidade quantitativa entre eles, demonstradas na Figura3 decidiu-se que as prosas seriam descartadas por completo. Caso houvesse prosa o suficiente para produzir um estudo robusto, este seria realizado separadamente das obras de poesia.

O conjunto final de análise contém apenas as poesias de Álvaro de Campos, Ricardo Reis e Alberto Caeiro, com a seguinte distribuição:

Heterônimo	**Obras**	**Percentual**
Alberto Caeiro	120	17.2%
Álvaro de Campos	324	46.5%
Ricardo Reis	253	36.3%
Total	**697**	**100.0%**

Tabela 2 – Distribuição por heterônimo

3.2.3 Formato e composição dos textos

Para compreender e visualizar tendências entre as obras, foram criadas diversas variáveis sintéticas (atributos) a partir das informações textuais contidas exclusivamente na variável `Corpo`. O código referente à criação de variáveis e geração de gráficos encontra-se disponível no *GitHub* (RIBEIRO, 2026a).

As variáveis criadas são apresentadas na Tabela 3:

A extração das informações seguiu, de forma generalizada, o seguinte algoritmo:

```
para toda Observacao em Dataset:
    x <- contar instancias([expressao regex] em Observacao.Corpo)
    Observacao.nova_variavel <- x
```

Variável	**Descrição**
QTD_Versos	Quantidade de versos
QTD_Palavras	Quantidade de palavras
QTD_Estrofes	Quantidade de estrofes
QTD_Tipos	Quantidade de palavras únicas no poema
TAM_Verso	Tamanho médio dos versos do poema, a partir da quantidade de palavras dividida pela de verso
DEN_Pontos	Densidade de pontuação (exclamação, interrogação, etc.), a partir da quantidade total de pontuação dividida pela de palavras
DEN_Exclam	Densidade de pontos de exclamação
DEN_Inter	Densidade de pontos de interrogação
DEN_Final	Densidade de pontos final
DEN_Virgula	Densidade de vírgulas
DEN_Pev	Densidade de ponto-e-vírgula
DEN_Elipse	Densidade de elipses
TAM_Sentenca	Quantidade média de palavras por sentença do poema, uma sentença é delimitada por quebras de linha e/ou pontuações
DEN_VERB	Densidade de verbos, a partir da quantidade total de verbos dividida pela de palavras
DEN_ADJ	Densidade de adjetivos
DEN_ADV	Densidade de advérbios
DEN_SUBS	Densidade de substantivos
DEN_PRON	Densidade de pronomes

Tabela 3 – Variáveis notáveis

Para densidades e médias houve a divisão pela quantidade de palavras, e para detecção de Verbos e outros componentes gramaticais foi utilizada uma biblioteca especializada na tarefa.

A partir de cada uma foi criado um gráfico para visualizar seu comportamento em relação aos Autores. Os gráficos menos discriminantes foram omitidos deste trabalho.

Na Figura4, observa-se em Alberto Caeiro uma tendência a quantidades maiores de estrofes; em contrapartida, os demais autores costumam apresentar apenas uma estrofe por obra. Nota-se também que, apesar do menor número de estrofes, Álvaro de Campos escreve poemas usualmente mais longos, enquanto Ricardo Reis possui a menor média de palavras por texto.

Na Figura5 embora não haja uma separação nítida na densidade de pontos, Álvaro de Campos faz uso mais frequente de pontuação. Além disso, o tamanho médio das sentenças de Alberto Caeiro é superior ao de Ricardo Reis, oferecendo uma distinção relevante entre ambos.

Para expandir o escopo de informações quantitativas disponíveis foram elaboradas

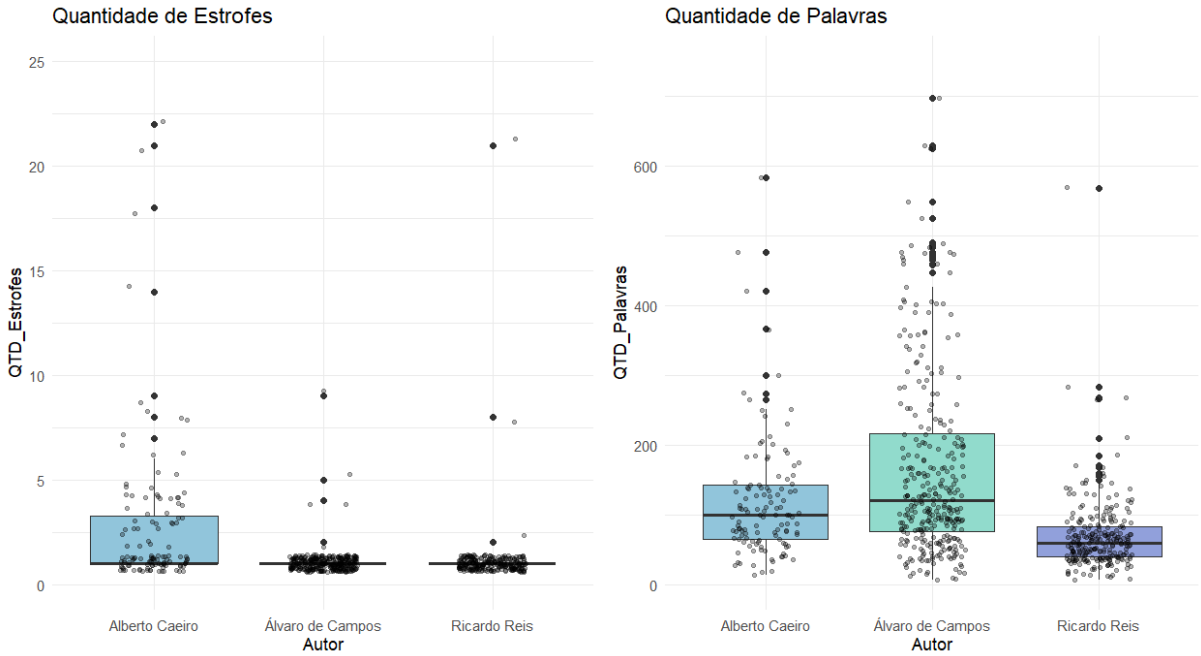

Figura 4 – Quantidade de estrofes e de palavras

Fonte: Autor

duas variáveis a mais, ambas referentes a variedade de vocabulário presente nos autores. A primeira foi "TTR"(*Type-Token Ratio*), calculada a partir da divisão entre a quantidade total de palavras únicas em um poema, pela quantidade total de palavras. Sua distribuição pode ser visualizada no Figura6:

Observa-se que Alberto Caeiro e Álvaro de Campos possuem riqueza vocabular semelhante, enquanto os textos de Ricardo Reis são frequentemente mais densos lexicalmente.

Já a segunda nova variável é a entropia dos textos, essencialmente uma maneira diferente de medir a riqueza de vocabulário da obra. A entropia dos textos foi calculada a partir do algoritmo abaixo, que segue a fórmula de entropia de Shannon:

$$H(X) = -\sum_{i=1}^{n} P(x_i) \log_b P(x_i)$$

```
para toda Observacao em Dataset:
  Palavras <- particao(em minusculo(Observacao.corpo), [espaco])
  remover vazios(Palavras)

  se Palavras = conjunto vazio:
    Observacao.entropia <- 0
  caso contrario:
    para toda palavra unica P em Palavras:
        P.probabilidade <- quantidade de P em Palavras / total de items
   em Palavras
```

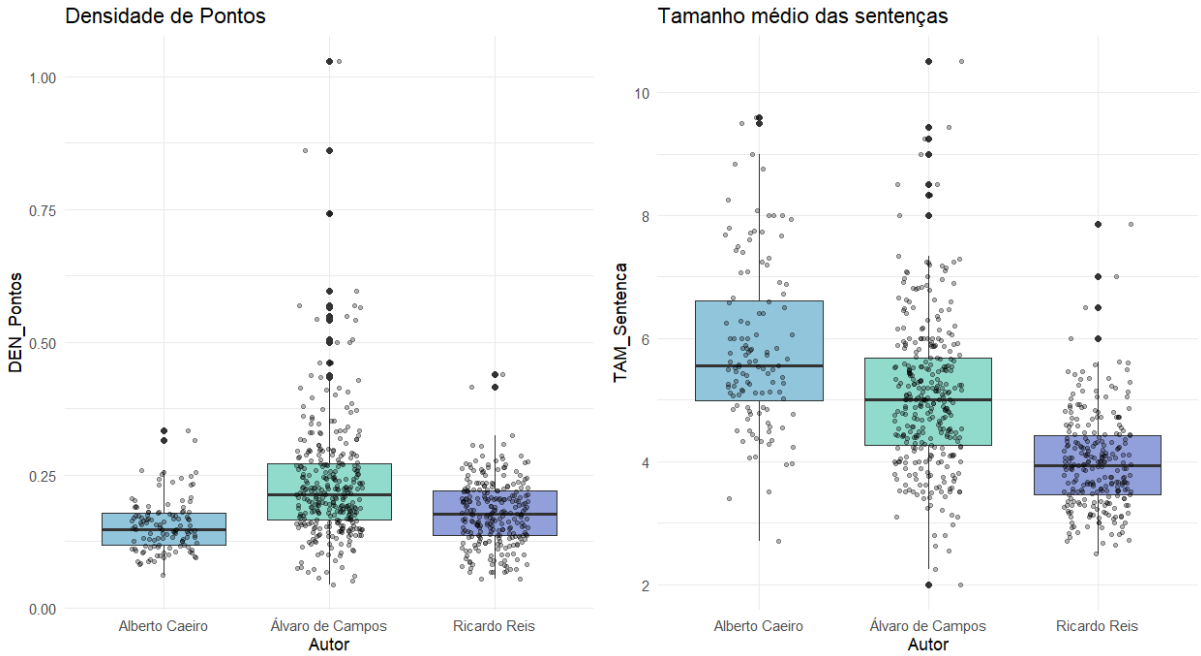

Figura 5 – Composição geral dos textos

Fonte: Autor

```
        P.entropia <- P.probabilidade * log2(probabilidade)

    Observacao.entropia <- -soma(P.entropia de todo P em Palavras)
```

Considerando que este cálculo é influenciado pela extensão do texto, aplicou-se uma normalização:

```
para toda Observacao em Dataset:
    [...]
    Observacao.entropia_norm <- -Observacao.entropia / log2(total de
   items em Palavras)
```

Tendo ambos valores registrados foi possível plotar o gráfico da Figura7:

Este reforça a importância da normalização e confirma a tendência observada no TTR, destacando a riqueza lexical característica de Ricardo Reis.

3.3 Métodos de classificação

Os algoritmos de classificação constituem o núcleo analítico deste trabalho, permitindo a identificação de padrões estilísticos que distinguem os heterônimos. A seguir, apresentam-se os fundamentos teóricos de cada método empregado, fundamentados na literatura clássica de aprendizado estatístico. Para uma descrição mais didática e aprofundada das formulações matemáticas e propriedades desses métodos, recomenda-se a consulta a James et al. (JAMES et al., 2013).

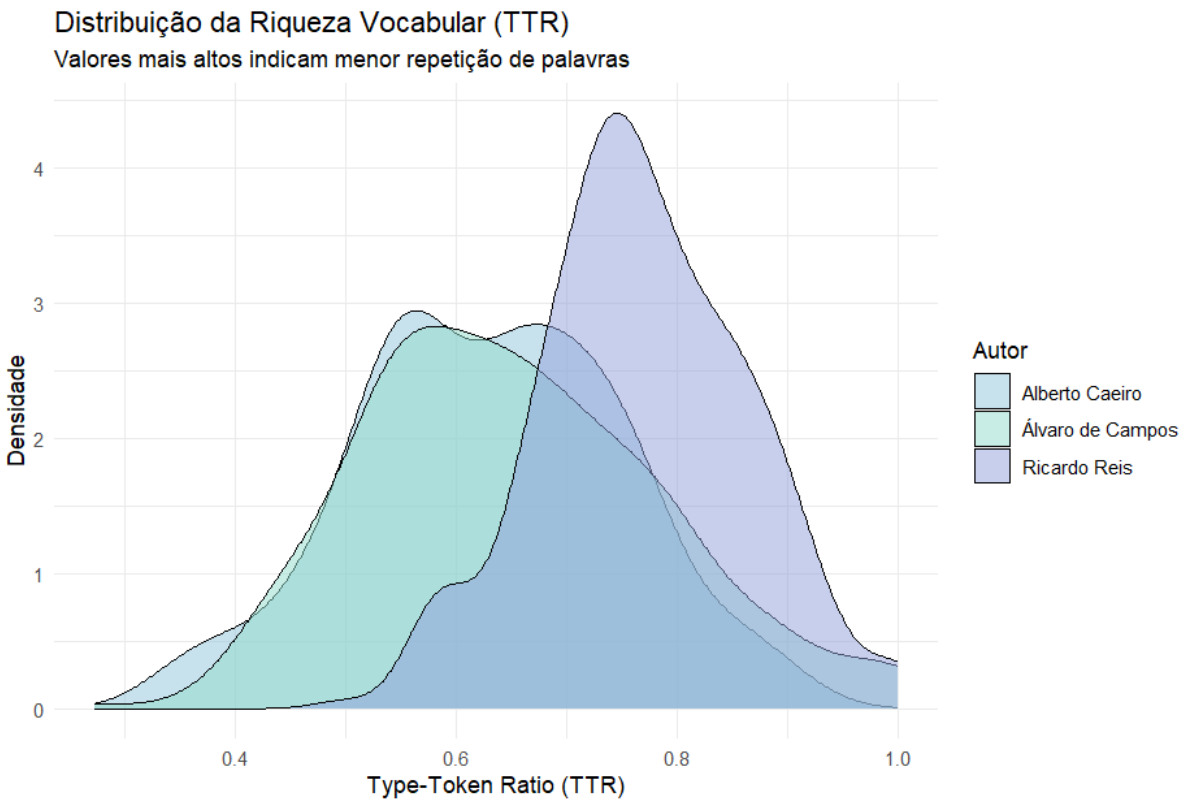

Figura 6 – Riqueza vocabular

Fonte: Autor

3.3.1 Árvore de decisão

A classificação por árvore de decisão consiste em segmentar o espaço de atributos através de partições binárias sequenciais. O modelo inicia-se em um nó raiz, que engloba a totalidade do conjunto, e seleciona repetidamente o atributo que apresenta o maior poder discriminante em relação às variáveis de classificação, utilizando critérios como a Entropia ou o Índice de Gini.

Durante a construção da árvore, cada nó interno representa uma partição baseada em um teste sobre uma variável independente específica — por exemplo, `"Tamanho >= X"` — cujos resultados direcionam o fluxo de dados para ramos subsequentes. Esse processo de divisão continua de forma descendente até que seja alcançado um nível de pureza satisfatório no nó ou outro critério de parada, como a profundidade máxima, seja atingido. Ao fim, a classificação mais comum na partição formada pelo nó final será atribuída à observação testada pelo modelo. Embora não se aplique diretamente a este estudo, o percentual de pureza do nó folha pode ser interpretado como a probabilidade de a observação pertencer a uma determinada classe.

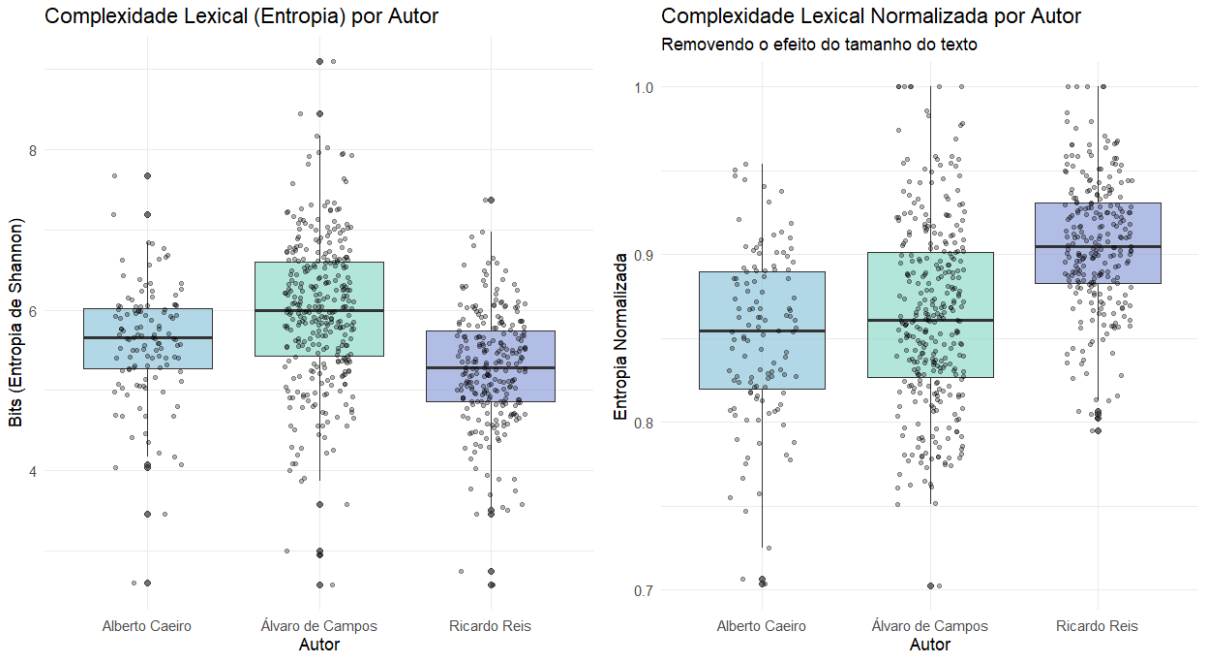

Figura 7 – Entropia antes e depois da normalização

Fonte: Autor

3.3.2 Floresta aleatória

A floresta aleatória (*random forest*) é um classificador que faz uso de diversas árvores de decisão para alcançar um resultado mais robusto. O modelo inicia-se com a replicação do conjunto original em diversos subconjuntos com uma seleção aleatória de observações e variáveis (técnica conhecida como *bagging*); ou seja, um atributo como "tamanho"pode não aparecer em uma parcela desses subconjuntos.

Em seguida, é construída uma árvore para cada subconjunto, populando a floresta. Ao fim, uma dada observação a ser classificada percorre todas as árvores, e sua classificação final é determinada pela resposta majoritária da floresta. Este método evita o enviesamento e a rigidez ao introduzir aleatoriedade no sistema, em vez de ser construído exclusivamente ao redor de um conjunto fixo de dados. Assim como na árvore simples, o percentual de árvores que "concordam"pode ser interpretado como a probabilidade de pertencimento.

3.3.3 Support Vector Machine

As Máquinas de Vetores de Suporte (SVMs) consistem em mapear as observações em um espaço n-dimensional referente a todas as variáveis do conjunto. Em seguida, busca-se a criação de um hiperplano que separa as classes de forma ótima, ou seja, que maximiza a distância (margem) entre o plano e as observações mais próximas de cada classe. As observações na fronteira são denominadas vetores de suporte, e constituem os

únicos pontos do conjunto de treinamento que exercem influência direta sobre a solução encontrada pelo modelo.

Quando os dados não são linearmente separáveis no espaço original, o SVM utiliza funções de *kernel* para mapear implicitamente os dados para um espaço de dimensionalidade superior, tornando as classes "linearmente"separáveis nesse novo ambiente. A classificação de uma nova observação é determinada pelo lado do hiperplano em que ela se posiciona.

3.3.4 Regressão logística

A regressão logística modela a probabilidade de pertencimento a uma classe a partir de uma combinação linear dos atributos de entrada, transformada pela função sigmoide, que restringe o resultado ao intervalo entre zero e um. Essa transformação permite interpretar a saída do modelo diretamente como a probabilidade de que uma observação pertença à classe de interesse, e a classificação final é atribuída à classe cuja probabilidade estimada supera um limiar predefinido, tipicamente 0,5.

Os parâmetros do modelo são estimados pelo método da máxima verossimilhança, que busca os coeficientes que tornam a probabilidade dos rótulos observados no treinamento tão alta quanto possível. Cada coeficiente estimado expressa a contribuição relativa do atributo correspondente para a probabilidade de pertencimento, conferindo ao modelo elevada interpretabilidade. Para tarefas com mais de duas categorias, como neste estudo, utiliza-se a regressão logística multinomial.

3.3.5 Regressão logística multinomial

A regressão logística multinomial estima, para cada observação, a probabilidade de pertencimento a cada uma das classes possíveis. O modelo atribui a cada classe um vetor de pesos próprio, e a probabilidade associada a cada categoria é calculada pela função *softmax*, que transforma os valores lineares em uma distribuição de probabilidades que soma 1. Durante o treinamento, os pesos são ajustados iterativamente de forma a maximizar a verossimilhança das classes observadas, penalizando combinações de pesos que atribuam baixa probabilidade à classe correta. Ao fim, a classificação de uma nova observação é determinada pela classe que receber a maior probabilidade estimada pelo modelo.

4 Resultados

4.1 Testes individuais

Inicialmente, foram executados testes individuais para os quatro modelos de classificação apresentados. O procedimento consistiu na partição do conjunto original em subconjuntos de treinamento (70%) e teste (30%), seguida pelo treinamento dos algoritmos e a subsequente avaliação de desempenho por meio da comparação entre as classificações previstas e os rótulos reais.

```
conjunto_de_estudo <- conjunto_original sem variaveis nao numericas

seleciona semente aleatoria(1234)
conjunto_treino <- 70% aleatorio do conjunto_de_estudo
conjunto_teste <- 30% restante do conjunto_de_estudo
```

Para garantir a comparabilidade, todos os modelos foram submetidos aos mesmos subconjuntos, utilizando-se uma semente aleatória fixa (`1234`). Embora a alteração da semente possa variar os resultados pontuais, os valores obtidos são indicativos de tendências de performance. Ressalta-se que variáveis não numéricas, como bibliografia e data, foram removidas para evitar erros de processamento e impedir o vazamento de dados (*data leakage*) — como ocorreria na variável "Bibliografia", que frequentemente cita o autor explicitamente.

```
modelo <- treina_modelo(conjunto_treino, variavel resposta em funcao das
    demais, classificacao)

previsoes <- previsa(modelo, conjunto_teste)
gerar matriz de confusao(previsoes, conjunto_teste.variavel_resposta)
```

4.1.1 Árvore de decisão

A árvore de decisão gerada (Figura 8) permite identificar as variáveis com maior poder discriminante. A *densidade de elipses* foi selecionada como o primeiro critério de partição (nó raiz), seguida pela *quantidade de estrofes* e pelo *tamanho de sentenças*. O atributo *tamanho do verso* também se destacou, sendo utilizado em três diferentes níveis da árvore.

O modelo inicial atingiu uma acurácia total de 0,8178. Conforme a matriz de confusão (Tabela 4), observa-se que, apesar do bom desempenho geral, há uma confusão recorrente entre Álvaro de Campos e Ricardo Reis.

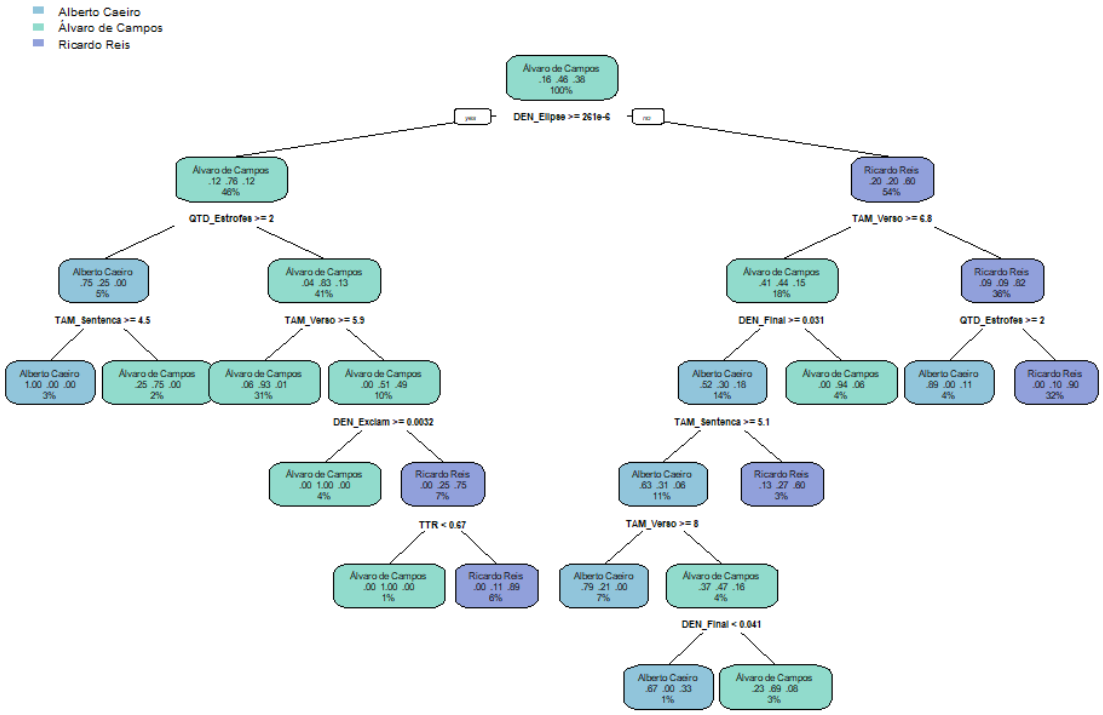

Figura 8 – Primeira árvore de decisão gerada

Fonte: Autor

Previsão	**Realidade**		
	Alberto Caeiro	Álvaro de Campos	Ricardo Reis
Alberto Caeiro	28	3	2
Álvaro de Campos	8	82	4
Ricardo Reis	6	16	65
Acurácia balanceada	0.8188	0.8528	0.8808

Tabela 4 – Matriz de confusão: Primeira árvore

Visando a simplificação do modelo e a redução do risco de sobreajuste (*overfitting*), aplicou-se a técnica de poda (*pruning*) (BOEHMKE; GREENWELL, 2019). A árvore podada (Figura 9) apresentou uma estrutura significativamente menor e um leve incremento na acurácia total, atingindo 0,8224.

Ao comparar o desempenho nas matrizes de confusão, observa-se que Álvaro de Campos apresenta o maior volume absoluto de classificações incorretas, com uma tendência recorrente do modelo em atribuir seus poemas a Ricardo Reis. Entretanto, como Campos possui a maior representatividade no corpus, seu percentual de acerto relativo (acurácia balanceada) permanece elevado, não sendo severamente prejudicado por essas inconsistências pontuais.

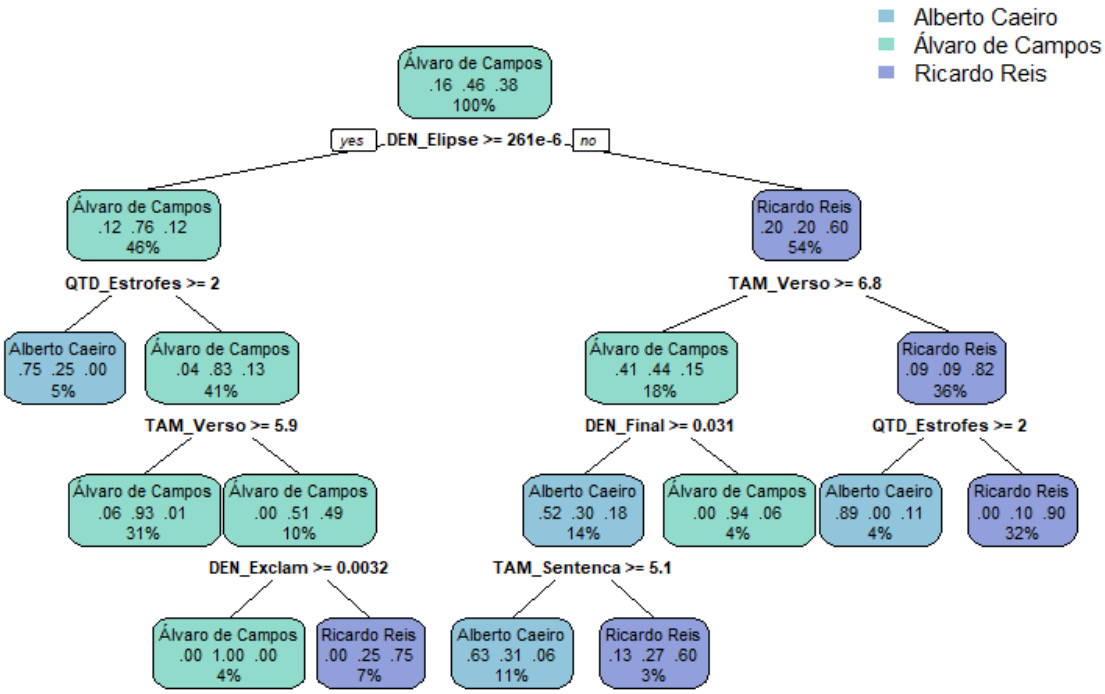

Figura 9 – Primeira árvore de decisão após poda

Fonte: Autor

Previsão	**Realidade**		
	Alberto Caeiro	Álvaro de Campos	Ricardo Reis
Alberto Caeiro	33	5	2
Álvaro de Campos	3	77	3
Ricardo Reis	6	19	66
Acurácia balanceada	0.8725	0.8546	0.8774

Tabela 5 – Matriz de confusão: Primeira árvore após poda

4.1.2 Floresta aleatória

O modelo de floresta aleatória obteve uma acurácia superior de 0,8598.

A implementação de floresta aleatória no R oferece uma funcionalidade especifica: imprimir a importância de cada variável no modelo. Analisando a importância das variáveis (Figura 10), identificou-se que a densidade de ponto-e-vírgula possuía a menor contribuição para o modelo. A remoção desta variável, contudo, não alterou a acurácia total, resultando em mudanças marginais nos acertos individuais de Caeiro e Campos.

Previsão	**Realidade**		
	Alberto Caeiro	Álvaro de Campos	Ricardo Reis
Alberto Caeiro	28	2	0
Álvaro de Campos	10	90	5
Ricardo Reis	4	9	66
Acurácia balanceada	0.8275	0.8792	0.9193

Tabela 6 – Matriz de confusão: Primeira floresta aleatória

Previsão	**Realidade**		
	Alberto Caeiro	Álvaro de Campos	Ricardo Reis
Alberto Caeiro	29	2	0
Álvaro de Campos	9	89	5
Ricardo Reis	4	10	66
Acurácia balanceada	0.8394	0.8786	0.9158

Tabela 7 – Matriz de confusão: Segunda floresta aleatória, sem ponto e vírgula

4.1.3 SVMs

Com a aplicação do SVM, os resultados indicaram uma acurácia total de 0,8084. Conforme a matriz de confusão (Tabela 8), percebe-se uma dificuldade acentuada na classificação correta de Alberto Caeiro, em grande parte por ser o autor com o menor volume de poemas no conjunto de dados. Mais a frente, será conduzido um experimento onde novas observações artificiais serão introduzidas no conjunto para tentar remediar o desbalanceamento.

Previsão	**Realidade**		
	Alberto Caeiro	Álvaro de Campos	Ricardo Reis
Alberto Caeiro	26	6	1
Álvaro de Campos	11	86	9
Ricardo Reis	5	9	61
Acurácia balanceada	0.7892	0.8372	0.8806

Tabela 8 – Matriz de confusão: SVM

4.1.4 Regressão logística multinomial

Os resultados da regressão logística multinomial apresentaram uma acurácia total de 0,8037. Trata-se do desempenho mais baixo entre os modelos testados individualmente, reforçando a dificuldade de distinguir o heterônimo minoritário. Por outro lado, vale notar

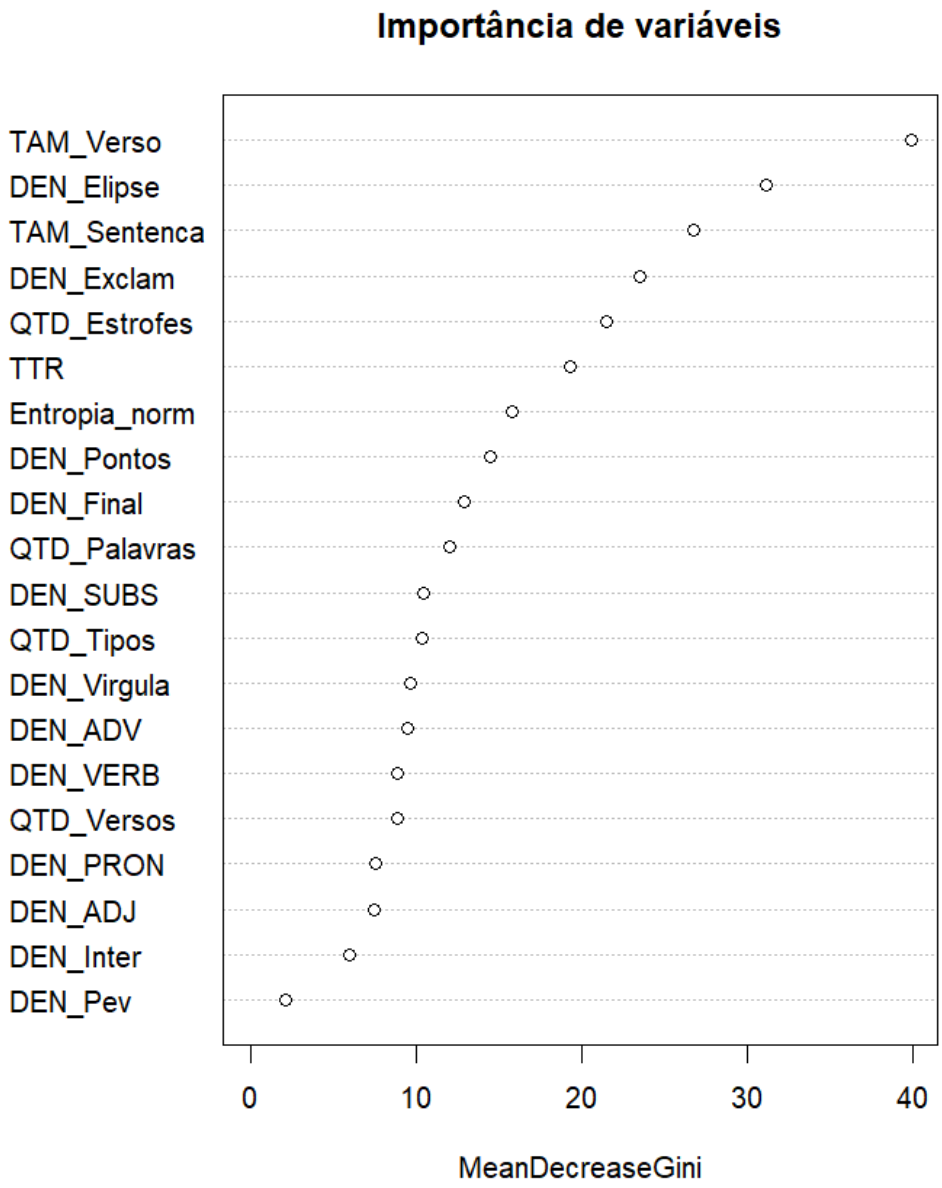

Figura 10 – Importância de variáveis

Fonte: Autor

que todos os modelos, incluindo este, performaram de forma consistente com Ricardo Reis, mantendo acurácias balanceadas elevadas para este autor.

4.1.5 Impacto da partição aleatória

As flutuações de desempenho observadas ao alterar a semente aleatória (Tabela 10) evidenciam a sensibilidade dos modelos à partição dos dados. Tais variações justificam a aplicação de métodos de validação cruzada para obter estimativas mais estáveis de performance.

Previsão	**Realidade**		
	Alberto Caeiro	Álvaro de Campos	Ricardo Reis
Alberto Caeiro	25	8	0
Álvaro de Campos	12	84	8
Ricardo Reis	5	9	63
Acurácia balanceada	0.7892	0.8372	0.8806

Tabela 9 – Matriz de confusão: Regressão logística multinomial

Semente	**Acurácia**			
	Árvore	Floresta	SVM	Regressão
1234	0.8224	0.8598	0.8084	0.8037
1274	0.8447	0.8689	0.8495	0.8495
5678	0.8486	0.9081	0.8324	0.8486

Tabela 10 – Diferentes acurácias por partição

4.2 Testes em escala

4.2.1 K-Fold Cross Validation

Para mitigar o viés da aleatoriedade, utilizou-se o método *K-Fold Cross Validation* com $K = 10$ partições. O procedimento consiste em dividir o conjunto de dados em K grupos, onde cada grupo atua como teste uma única vez enquanto o modelo é treinado nos demais $K - 1$ grupos (JAMES et al., 2013). Os resultados consolidados (Tabela 11) confirmam a superioridade da Floresta Aleatória como o classificador mais eficiente para este problema.

Modelo	**Acurácia**
Árvore	0.8377811
Floresta	0.8691850
SVM	0.8333407
Regressão	0.8262179

Tabela 11 – Acurácias via *K-Fold CV*

4.3 Observações sintéticas

Considerando a disparidade na proporção de obras por autor, aplicou-se a técnica SMOTE (*Synthetic Minority Oversampling Technique*) para balancear o conjunto de dados. O método gera observações artificiais para a classe minoritária (Alberto Caeiro) calculando pontos intermediários entre vetores de vizinhos próximos, garantindo que os novos dados possuam variabilidade e não sejam meras duplicatas.

Heterônimo	**Obras**	**Percentual**
Alberto Caeiro	240	29.4%
Álvaro de Campos	324	39.7%
Ricardo Reis	253	30.9%
Total	**817**	**100.0%**

Tabela 12 – Distribuição por heterônimo pós balanceamento

Com a duplicação das observações de Caeiro, o experimento com *K-Fold Cross Validation* foi repetido. Os resultados (Tabela 13) revelam uma melhora em todos os modelos.

Modelo	**Acurácia**
Árvore	0.8417941
Floresta	0.8915343
SVM	0.8649624
Regressão	0.8496879

Tabela 13 – Acurácias do conjunto balanceado via *K-Fold CV*

Nota-se um incremento consistente na eficácia de todos os modelos, com destaque para a Floresta Aleatória, que atingiu o desempenho mais robusto do estudo. Diante dessa performance, realizou-se uma análise individualizada desse modelo para verificar o comportamento da matriz de confusão em uma partição aleatória (semente `1234`) do conjunto balanceado. A acurácia obtida foi de 0,8947.

Previsão	**Realidade**		
	Alberto Caeiro	Álvaro de Campos	Ricardo Reis
Alberto Caeiro	62	10	3
Álvaro de Campos	5	85	5
Ricardo Reis	0	3	74
Acurácia balanceada	0.9266	0.9001	0.9421

Tabela 14 – Matriz de confusão: Floresta aleatória em conjunto balanceado

Estes resultados são satisfatórios e concluem a experimentação realizada no estudo.

5 Conclusão

Ao longo deste trabalho, foi possível realizar uma análise estatística abrangente das obras de três dos principais heterônimos de Fernando Pessoa: Alberto Caeiro, Álvaro de Campos e Ricardo Reis. Além da análise individual, o estudo proporcionou uma visão panorâmica da distribuição da produção literária do autor entre suas diversas identidades poéticas.

Todo o fluxo metodológico — desde a extração das obras via *web scraping*, a engenharia de atributos estilométricos e a visualização de dados, até o treinamento de modelos e a geração de dados sintéticos — foi desenvolvido integralmente na linguagem R. Tal escolha demonstrou a versatilidade do ecossistema de bibliotecas da linguagem para tarefas complexas de Ciência de Dados. As variáveis sintéticas criadas mostraram-se fundamentais para a eficácia dos modelos preditivos implementados: Árvore de Decisão, Floresta Aleatória, SVM e Regressão Logística Multinomial.

Os resultados obtidos foram altamente satisfatórios. Em sua configuração mais robusta — utilizando validação cruzada (*K-Fold*) e balanceamento de classes via SMOTE — as acurácias médias situaram-se entre 84% e 89%. A Floresta Aleatória destacou-se como o modelo mais eficiente, atingindo o patamar superior de desempenho. A análise de importância de variáveis revelou que o `TAM_Verso`, a `DEN_Elipse` e o `TAM_Sentenca` foram os atributos mais determinantes para a distinção estilística, validando a premissa de que elementos quantitativos podem capturar nuances da subjetividade artística.

Dessa forma, conclui-se que os modelos empregados e os atributos selecionados são plenamente capazes de classificar, com elevado grau de precisão, a autoria heteronímica de Fernando Pessoa no recorte estudado.

Trabalhos Futuros

Para o desdobramento desta pesquisa, sugere-se a aplicação de algoritmos de maior complexidade, como *XGBoost* ou arquiteturas de Redes Neurais, sobre o conjunto de atributos estilométricos aqui propostos. Adicionalmente, o estudo pode ser expandido para o gênero prosa, explorando as particularidades de heterônimos como Bernardo Soares. Por fim, vislumbra-se a possibilidade de integrar estes achados quantitativos a estudos da crítica literária tradicional, oferecendo uma base empírica que possa enriquecer as análises qualitativas sobre a fragmentação do "eu"na obra pessoana.

Referências

AHMED, S.; SINGH, M.; DOHERTY, B.; RAMLAN, E.; HARKIN, K.; BUCHOLC, M.; COYLE, D. An empirical analysis of state-of-art classification models in an it incident severity prediction framework. **Applied Sciences**, v. 13, n. 6, 2023. ISSN 2076-3417. Disponível em: <https://www.mdpi.com/2076-3417/13/6/3843>. Citado na página 12.

AREAL, L.; ESTEVES, J. C.; NEVES, J. M. **ArquivoPessoa**. 2009. <http://arquivopessoa.net>. Citado 2 vezes nas páginas 9 e 13.

BIRD, S.; KLEIN, E.; LOPER, E. **Natural Language Processing with Python**. 1st. ed. [S.l.]: O'Reilly Media, Inc., 2009. ISBN 0596516495. Citado na página 12.

BOEHMKE, B.; GREENWELL, B. M. **Hands-On Machine Learning with R**. 1. ed. [S.l.]: Chapman and Hall/CRC, 2019. Citado na página 24.

JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. **An Introduction to Statistical Learning: with Applications in R**. Springer, 2013. Disponível em: <https://faculty.marshall.usc.edu/gareth-james/ISL/>. Citado 3 vezes nas páginas 11, 19 e 28.

JUSTINO, E. J. R. **O Uso de Atributos Estilométricos na Identificação da Autoria de Textos**. Dissertação (Mestrado) — Pontifícia Universidade Católica do Paraná, 2010. Citado 2 vezes nas páginas 11 e 12.

MATSUMOTO, F.; NUNES, I.; CâMARA, I.; POCCIOTTI, J.; SEPADA, L. **Como Machine Learning consegue diferenciar heterônimos de Fernando Pessoa**. 2020. <https://medium.com/turing-talks/como-machine-learning-consegue-diferenciar-heterÃťnimos-de-fernando-pessoa-156d0d52a478>. Citado 2 vezes nas páginas 8 e 10.

NIRKHI, S.; DHARASKAR, R. V. **Comparative study of Authorship Identification Techniques for Cyber Forensics Analysis**. 2013. Disponível em: <https://arxiv.org/abs/1401.6118>. Citado na página 10.

RIBEIRO, P. D. A. **PreProsFP**. 2026. <https://github.com/PedroRibeiroA123/TCC-Quantificando-Fernando-Pessoa/blob/main/PreProcessamento.R>. Citado na página 16.

_____. **Repositorio**. 2026. <https://github.com/PedroRibeiroA123/TCC-Quantificando-Fernando-Pessoa>. Citado na página 9.

_____. **ScraperFP**. 2026. <https://github.com/PedroRibeiroA123/TCC-Quantificando-Fernando-Pessoa/blob/main/ScraperFP.R>. Citado na página 14.

SEL, S.; HANBAY, D. E-mail classification using natural language processing. In: **2019 27th Signal Processing and Communications Applications Conference (SIU)**. [S.l.: s.n.], 2019. p. 1–4. Citado na página 12.

SHEN, A.; TONG, R.; DENG, Y. Application of classification models on credit card fraud detection. In: **2007 International Conference on Service Systems and Service Management**. [S.l.: s.n.], 2007. p. 1–4. Citado na página 12.

SKORINKIN, D.; OREKHOV, B. "reis melhor do que eu": los heterónimos de pessoa desde una perspectiva estilométrica. **Literatura: teoría, historia, crítica**, v. 25, n. 2, 2023. Citado na página 11.

SOUZA, W. **Heterônimos de Fernando Pessoa**. 2026. <https://brasilescola.uol.com.br/literatura/fernando-pessoa-seus-heteronimos.htm>. Citado na página 8.

TAHA, K.; YOO, P. D.; YEUN, C.; HOMOUZ, D.; TAHA, A. A comprehensive survey of text classification techniques and their research applications: Observational and experimental insights. **Computer Science Review**, v. 54, p. 100664, 2024. ISSN 1574-0137. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1574013724000480>. Citado na página 8.

TEIXEIRA, J.; COUTO, M. Automatic distinction of fernando pessoas' heteronyms. In: . [S.l.: s.n.], 2015. v. 9273. ISBN 978-3-319-23484-7. Citado 2 vezes nas páginas 8 e 10.

YAN, X.; XIAO, Y.; JIN, Y. Generative large language models explained [ai-explained]. **IEEE Computational Intelligence Magazine**, v. 19, n. 4, p. 45–46, 2024. Citado na página 12.

YUE, X.; DI, G.; YU, Y.; WANG, W.; SHI, H. Analysis of the combination of natural language processing and search engine technology. **Procedia Engineering**, v. 29, p. 1636–1639, 2012. ISSN 1877-7058. 2012 International Workshop on Information and Electronics Engineering. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1877705812001968>. Citado na página 12.

ZUMEL, N.; MOUNT, J. **Practical data science with R**. [S.l.]: Manning, 2014. ISBN 9781617291562 1617291560. Citado na página 11.